

Wolf-Rayet Search

Construcción reproducible de muestras y ranking fotométrico de candidatas Wolf-Rayet galácticas

Resumen técnico

Este proyecto desarrolla un pipeline reproducible y flexible para construir muestras astronómicas, entrenar modelos y producir una lista priorizada de fuentes Gaia compatibles con estrellas Wolf-Rayet (WR). El modelo asigna a cada fuente un score de compatibilidad y usa ese valor para ordenar las candidatas. La confirmación corresponde al seguimiento espectroscópico.

La reproducibilidad se apoya en snapshots de los catálogos, configuraciones versionadas, identificadores de entrenamiento, hashes de datasets y artefactos auditables. La separación entre adquisición, filtros, modelado y scoring permite cambiar requisitos fotométricos o astrométricos, comparar nuevos algoritmos e incorporar posteriormente información espectral sin sustituir el pipeline completo.

Las etiquetas provienen de dos fuentes astronómicas con funciones distintas. El Galactic Wolf Rayet Catalogue aporta las WR conocidas [2, 1]; SIMBAD aporta clases estelares que pueden confundirse fotométricamente con ellas [6]. Gaia, 2MASS y WISE aportan las mediciones usadas para construir los datasets y entrenar los modelos.

El problema se formula como ranking de una clase rara. Una lista top-K contiene las K fuentes con mayor score; ese tamaño representa un presupuesto concreto de revisión o seguimiento. La evaluación prioriza la recuperación de WR dentro de esas listas, Average Precision y el comportamiento a baja tasa de falsos positivos.

Antes del entrenamiento se aplica un locus de color: seis relaciones color-color ajustadas sobre las WR conocidas que delimitan la región fotométrica admitida. Este filtro reduce el volumen de contaminantes que llega a los modelos.

En el subconjunto más amplio, que acepta calidad fotométrica A o B en 2MASS/WISE y aplica únicamente estos requisitos, el filtro de color conserva 331 de 347 WR (95,4 %) y reduce la muestra negativa de SIMBAD de 66.787 a 33.343 fuentes.

La Figura 1 resume el recorrido de una fuente desde los catálogos de origen hasta la lista de seguimiento. Cada etapa deja archivos y diagnósticos reproducibles.

Pipeline reproducible de búsqueda de candidatas Wolf-Rayet

De catálogos etiquetados a una lista priorizada para seguimiento espectroscópico




Figura 1: Flujo del proyecto: adquisición, construcción de subconjuntos, filtrado, ranking y seguimiento espectroscópico.

Estado de esta entrega

El experimento principal entrenó 144 configuraciones: ocho variantes de dataset, dos conjuntos de features, tres algoritmos y tres estrategias de desbalance. `run_v3_main` agrupa esos entrenamientos y sus métricas.

La *prediction pool* divide el cielo en 675 regiones de consulta. Gaia devuelve las fuentes con la fotometría requerida dentro de una envolvente amplia de color; después se evalúan localmente el locus, la calidad fotométrica y la astrometría de cada variante. El build activo se registra con el identificador interno `pool_exact_union_acquisition_v1`. El snapshot del 26 de julio de 2026 contiene 673 de 675 regiones terminadas y dos fallidas: 184,8 millones de fuentes adquiridas y 64,9 millones elegibles para scoring. Antes del ranking se reintentarán las dos regiones fallidas y se auditarán la cobertura y los manifiestos de la pool.

1. Catálogos de origen y muestras etiquetadas

Las identidades, etiquetas y mediciones proceden de las siguientes fuentes:

Fuente	Uso en el proyecto
Galactic WR Catalogue	Identidad y tipo espectral de WR galácticas conocidas.
Gaia DR3	<code>source_id</code> , astrometría, fotometría G/BP/RP y tablas oficiales de crossmatch [3].
2MASS	Fotometría infrarroja cercana J/H/Ks [4].
AllWISE	Fotometría infrarroja media W1/W2 [5].
SIMBAD	Identidades y tipos de las clases usadas como comparación [6].
VizieR	Consulta de respaldo para contrapartes 2MASS o AllWISE ausentes en el crossmatch de Gaia [7].

Cuadro 1: Procedencia de las identidades, etiquetas y mediciones.

Muestra positiva WR

El snapshot local del Galactic WR Catalogue v1.33 contiene 705 entradas. De ellas, 442 declaran un alias Gaia DR3 explícito. Ese alias fija la identidad Gaia de la fuente. El snapshot HTML/CSV, su fecha y su SHA-256 quedan guardados para reproducir la selección.

La fotometría infrarroja se obtiene primero desde los crossmatches oficiales de Gaia hacia 2MASS y AllWISE. Para las fuentes sin contraparte, el fallback consulta VizieR por coordenadas: `II/246/out` para 2MASS y `II/328/allwise` para AllWISE. Cada cone search se centra en las coordenadas ICRS de Gaia y utiliza un radio de 5 segundos de arco, sin límite de filas y con un timeout de 180 segundos.

Cuando la consulta devuelve una sola contraparte dentro de 5 segundos de arco, esta se conserva. Si aparecen varias, el pipeline selecciona la coincidencia solo cuando queda una contraparte única dentro de 1,5 segundos de arco. Los grupos que todavía contienen varias coincidencias se vuelven a evaluar con un límite de 1,0 segundo de arco; si la ambigüedad persiste, la fuente queda sin fallback. Para cada match aceptado se guardan el identificador del catálogo, la separación angular recalculada, la fotometría, sus incertidumbres, los flags de calidad y `match_method=vizier_cone`. Las coordenadas no se propagan entre la época de Gaia y la época del catálogo externo, por lo que la separación registrada también funciona como control de auditoría.

La prueba de sensibilidad de procedencia IR favoreció el uso de todas las WR disponibles: el modelo con la cohorte completa igualó o superó al ajuste restringido a contrapartes nativas de Gaia.

La Figura 2 muestra cuántas fuentes permanecen después de cada etapa. La caída entre catálogo, alias Gaia, cobertura fotométrica y locus identifica el origen de cada reducción.

Retención por etapa en la variante relaxed_photometry





Figura 2: Retención de las muestras WR y SIMBAD en `relaxed_photometry`.

Muestra de comparación SIMBAD

La consulta SIMBAD reúne estrellas de emisión, Be, T Tauri, objetos jóvenes, gigantes rojas, AGB, estrellas de carbono, variables, binarias y supergigantes azules. Los identificadores y tipos WR se retiran antes del enriquecimiento fotométrico. La etiqueta 0 representa este conjunto de clases consultadas; su interpretación queda limitada a esa población de comparación.

La Figura 3 presenta la composición adquirida. Los topes de 10.000 filas por grupo pertenecen al diseño de consulta y explican las barras de igual longitud.



La muestra reúne las clases contaminantes seleccionadas en las consultas SIMBAD.

Figura 3: Composición de la muestra SIMBAD por clase de consulta.

2. Construcción de los subconjuntos de entrenamiento

A partir de la muestra WR y la muestra SIMBAD enriquecidas con la misma fotometría, el pipeline construye ocho variantes de dataset. Cada variante es un subconjunto de fuentes preparado para entrenar y evaluar modelos bajo una combinación concreta de calidad fotométrica y calidad astrométrica. Comparar estas variantes permite medir cuánto cambia el ranking al aumentar la exigencia fotométrica o astrométrica y cuánto disminuye, a la vez, el número de WR disponibles.

Cada dataset reúne las dos clases y utiliza una fila por fuente Gaia. Sus columnas contienen:

- la etiqueta `target`: 1 para una WR conocida y 0 para una fuente de la muestra SIMBAD;
- fotometría, astrometría y colores derivados;

- procedencia de los crossmatches y controles de calidad;
- diagnósticos del locus;
- la partición asignada para modelado.

Cada variante pasa después por el filtro de color, la división entre train, holdout y calibración, y la selección de filas con features completas. Los archivos Parquet y las tablas DuckDB guardan resultados intermedios para reproducir cada paso.

Criterios que generan las ocho variantes

Los nombres de las variantes codifican dos decisiones. El prefijo `strict` o `relaxed` indica la calidad aceptada en 2MASS y WISE. El sufijo `photometry`, `parallax_soft`, `poe_2` o `poe_3` indica el requisito astrométrico. POE abrevia *parallax over error*, la razón entre la paralaje y su incertidumbre. Cada combinación se aplica por igual a las filas WR y SIMBAD antes del entrenamiento.

Componente	Selección
<code>strict</code>	Gaia G/BP/RP, 2MASS J/H/Ks y WISE W1/W2 disponibles; calidad A en las bandas requeridas de 2MASS y WISE.
<code>relaxed</code>	La misma cobertura, con calidad A o B en las bandas requeridas de 2MASS y WISE.
<code>photometry</code>	Sin corte por signo o significancia de la paralaje durante la construcción del subconjunto.
<code>parallax_soft</code>	$\text{parallax} > 0$; funciona como comparación intermedia, pero no garantiza por sí sola una solución astrométrica precisa.
<code>poe_2</code>	$\text{parallax} > 0$ y $\text{parallax_over_error} \geq 2$; subconjunto astrométrico moderado.
<code>poe_3</code>	$\text{parallax} > 0$ y $\text{parallax_over_error} \geq 3$; subconjunto astrométrico más restrictivo.

Cuadro 2: Componentes usados para formar las variantes.

Cada familia, `strict` o `relaxed`, genera cuatro subconjuntos: fotométrico, paralaje positivo, $\text{POE} \geq 2$ y $\text{POE} \geq 3$. Por ejemplo, la variante `relaxed_poe_2` contiene fuentes con calidades infrarrojas A o B, paralaje positivo y $\text{POE} \geq 2$. Los modelos se entrenan por separado sobre cada subconjunto para comparar cobertura, recuperación de WR y control de falsos positivos. El corte $\text{POE} \geq 5$ se utiliza en auditorías específicas y queda fuera de la grilla principal.

Las ocho variantes entrenadas son `strict_photometry`, `strict_parallax_soft`, `strict_poe_2`, `strict_poe_3` y sus cuatro equivalentes `relaxed`. El nombre `photometry` describe la construcción del subconjunto y señala que no se corta por signo o significancia de la paralaje. Al preparar las matrices, los modelos actuales todavía utilizan la paralaje como feature y exigen un valor finito. Una fuente sin paralaje completa el export de auditoría, pero queda fuera del ajuste y del scoring de estos modelos.

Archivos generados antes del entrenamiento

1. **Exports base.** Contienen las fuentes que cumplen la cobertura, la calidad y el requisito astrométrico de una variante. Las muestras WR y SIMBAD permanecen en archivos separados.
2. **Exports con locus.** Añaden residuos, umbrales, número de planos atípicos y el indicador booleano `color_locus_keep`, que registra si la fuente supera el filtro de color. Todas las filas permanecen disponibles para auditoría.
3. **Subconjuntos reducidos para modelado.** Reúnen las filas con `color_locus_keep=True`, asignan train para ajuste, holdout para evaluación o calibración para selección de umbral, y reducen los negativos de train a la proporción configurada.

Esta secuencia aplica el locus a las dos clases antes del split. Train, holdout y calibración comparten exactamente la misma regla de elegibilidad.

3. Locus de color y regla de elegibilidad

El locus delimita la zona del espacio de colores ocupada por las WR de referencia. Utiliza seis planos intra-misión: tres combinaciones de los colores Gaia G-BP, G-RP y BP-RP, y tres combinaciones de J-H, J-Ks y H-Ks en 2MASS. W1-W2 aporta una feature adicional al modelo. Las bandas W1 y W2 entregan un solo color, por lo que WISE queda fuera del ajuste de planos.

Los colores del locus se calculan dentro de cada misión. Esta decisión mantiene la frontera independiente de diferencias de época, calibración y procedencia entre crossmatches.

Transformación y ajuste robusto

$$T(c) = \text{sign}(c) \ln(1 + |c|), \quad (1)$$

$$T(y_i) = \beta_0 + \beta_1 T(x_i) + \epsilon_i, \quad (2)$$

$$r_i = T(y_i) - [\beta_0 + \beta_1 T(x_i)]. \quad (3)$$

Cada plano se ajusta con HuberRegressor [8]. El estimador limita la influencia de residuos grandes sobre la pendiente. El umbral del plano es el percentil 97,5 de $|r|$ en la muestra WR.

$$N_{\text{out},i} = \sum_p \mathbb{I}(|r_{ip}| > q_{0.975,p}), \quad \text{keep}_i = \mathbb{I}(N_{\text{out},i} < 2).$$

La primera implementación retiraba una fuente con $N_{\text{out}} \geq 1$. La regla actual exige $N_{\text{out}} \geq 2$. En la variante relaxed con selección fotométrica, el cambio conserva 10 WR adicionales y 6.838 fuentes SIMBAD adicionales:

Regla	WR conservadas	SIMBAD conservadas
Outlier en al menos 1 plano	321/347 (92,5 %)	26.505/66.787 (39,7 %)
Outlier en al menos 2 planos	331/347 (95,4 %)	33.343/66.787 (49,9 %)

Se eligió el límite de dos planos porque una desviación aislada puede provenir de una medición afectada por crowding, extinción o error fotométrico. Dos desviaciones aportan evidencia más estable antes de retirar una fuente. El clasificador se encarga después de ordenar las fuentes que permanecen.

signed_log1p reemplazó el ajuste log10 restringido a colores positivos. La transformación actual conserva el signo, acepta cero y utiliza todas las filas con valores finitos.

La Figura 4 muestra dos planos representativos. Las bandas punteadas delimitan el umbral y permiten ver el solapamiento que permanece para el clasificador.




Figura 4: Planos Gaia y 2MASS del locus en `relaxed_photometry`.

4. Split, reducción de negativos y features

El orden de operaciones es: locus, holdout, reducción de negativos y entrenamiento. El holdout se asigna mediante un hash estable de `source_id`, estratificado por clase. Cerca del 20 % de cada clase queda reservado para evaluación.

Todas las WR restantes pasan a train. Los negativos de train se seleccionan a razón 10:1 mediante estratos de cuantiles de color. El resto de los negativos forma `threshold_calibration`, una muestra amplia destinada a estresar la tasa de falsos positivos y elegir el umbral de decisión. Esta muestra contiene únicamente negativos y no interviene en el ajuste de los parámetros del modelo.

El umbral se obtiene después de entrenar cada configuración. Para representar la clase positiva se usan los scores *out-of-fold* de las WR de train: cada score procede de un fold en el que esa WR no participó en el ajuste. Para la clase negativa se usan los scores de todo `threshold_calibration`, calculados con el modelo ajustado sobre train. Sobre ambas distribuciones se selecciona el umbral que maximiza F_β , con $\beta = 1,5$, sujeto a una precisión mínima de 0,5 y una *balanced accuracy* mínima de 0,5. También se registran la fracción de negativos de calibración que supera el umbral y los percentiles 50, 90, 95 y 99 de sus scores.

El holdout permanece fuera del entrenamiento y de esta selección. El umbral ya fijado se aplica al holdout para calcular las métricas dependientes de umbral. Average Precision y las métricas top-K se calculan directamente sobre el ranking de scores y, por tanto, no dependen de ese corte. En la prediction pool, cada modelo conservará su propio umbral, aunque el producto principal seguirá siendo una lista ordenada de candidatos.

En `relaxed_photometry`, antes de exigir completitud de features, train contiene 262 WR y 2.620 negativos; holdout contiene 69 WR y 6.634 negativos; y `threshold_calibration`, 24.089 negativos. La matriz final del XGBoost destacado evalúa 68 WR y 6.558 negativos en holdout.

Cada una de las ocho variantes de dataset se representa mediante dos sets de features. Esto produce 16 combinaciones variante-features antes de cruzarlas con los algoritmos y las estrategias de balanceo.

1. `colors_parallax`: siete colores intra-misión (BP_RP, G_BP, G_RP, J_H, J_K, H_K y W1_W2) más parallax. Esta representación tiene ocho variables y no incorpora incertidumbres astrométricas;
2. `colors_parallax_error`: las ocho variables anteriores más `parallax_error` y `parallax_over_error`. Esta representación tiene diez variables.

Por tanto, `photometry` identifica un subconjunto sin corte astrométrico previo y no un modelo que ignore la astrometría. Las dos matrices actuales exigen una paralaje finita; la segunda exige además error de paralaje y POE finitos. Las coordenadas galácticas se reservan para diagnósticos espaciales. La paralaje aporta información de escala; su inversa se interpreta únicamente como aproximación en las visualizaciones que aplican controles de calidad.


`parallax_over_error` está determinada por las otras dos variables,

$$\text{parallax_over_error} = \frac{\text{parallax}}{\text{parallax_error}},$$

por lo que no aporta una tercera medición independiente. Se incluyó para que los modelos de árboles pudieran separar directamente por significancia astrométrica, además de distinguir la escala de la paralaje y el tamaño de su incertidumbre. La grilla permite evaluar esta decisión al comparar, para una misma variante, algoritmo y sampler, el set con y sin esas dos variables. En las 72 comparaciones emparejadas de `run_v3_main`, el set con errores obtuvo mayor AP en 44 casos y una diferencia media de AP de +0,009. La mejora es modesta: respalda conservar ambas representaciones, pero no demuestra que las tres variables astrométricas sean necesarias. Una ablación posterior puede comparar `parallax_error` y `parallax_over_error` por separado.

La Figura 5 muestra la cobertura espacial de las fuentes etiquetadas y ayuda a detectar concentraciones heredadas de los catálogos.

Distribución galáctica de la referencia y la muestra negativa



$l = 0^\circ$ al centro y longitud creciente hacia la izquierda. Las coordenadas se reservan para diagnóstico espacial.

Figura 5: Distribución galáctica de las muestras WR y SIMBAD.

Modelos y remuestreo

Una configuración de entrenamiento queda definida por cuatro elecciones: una variante de dataset, un set de features, un algoritmo y una estrategia de balanceo. La grilla combina las ocho variantes con dos sets de features, Random Forest, HistGradientBoosting y XGBoost, y tres estrategias de balanceo: ponderación nativa, SMOTE y SMOTE-ENN. El producto $8 \times 2 \times 3 \times 3$ da las 144 configuraciones reportadas.

El remuestreo se ejecuta dentro de cada fold de validación cruzada. La opción registrada como `none` aplica los pesos de clase del estimador y omite la generación de ejemplos sintéticos. SMOTE y SMOTE-ENN generan o depuran ejemplos dentro del fold y usan pesos neutros. BayesSearchCV prueba 25 combinaciones de hiperparámetros por configuración y optimiza Average Precision. XGBoost y SMOTE siguen las formulaciones de Chen y Guestrin [10] y Chawla et al. [11].

5. Evaluación y ranking de modelos

Las métricas de decisión son Average Precision, Precision-Recall, recuperación top-K y recall a FPR fijo. Estas métricas describen directamente la clase WR y el tamaño de la lista de seguimiento. La curva ROC queda como diagnóstico, ampliada en la región de FPR bajo. Precision-Recall ofrece una lectura más informativa bajo fuerte desbalance [12].

Recall@K es la fracción de WR del holdout recuperada entre las K fuentes con mayor score. Precision@K es la fracción de WR dentro de esas K fuentes. Estas dos métricas convierten el ranking en una cantidad directa de objetos por revisar.

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN}$$

$$AP = \sum_n (R_n - R_{n-1}) P_n.$$

La Figura 6 compara las 144 configuraciones. El frente superior combina alta AP con recuperación temprana; la estabilidad entre train, validación cruzada y holdout se revisa por separado.




Figura 6: Average Precision, recuperación top-K y perfiles representativos de la grilla.

Modelos mejor rankeados

El ranking compuesto pondera Recall@100 (35 %), AP (25 %), Precision@100 (15 %), Recall@50 (10 %), precisión en el umbral (10 %) y recall en el umbral (5 %), con una penalización suave por FPR. El score ordena el frente de compromiso. Los controles de estabilidad determinan el estado final.

#	Variante	Features	Modelo / sampler	Score	AP	R@50	R@100	P@100	Estado
1	relaxed_photometry	colors+parallax+error	XGB / none	0,588	0,535	0,500	0,706	0,480	Possible overfitting
2	strict_photometry	colors+parallax	XGB / none	0,578	0,524	0,484	0,710	0,440	Possible overfitting
3	strict_photometry	colors+parallax+error	XGB / none	0,577	0,498	0,452	0,742	0,460	Possible overfitting
4	relaxed_photometry	colors+parallax+error	HGB / none	0,574	0,537	0,500	0,662	0,450	Possible overfitting
5	strict_poe_2	colors+parallax+error	XGB / SMOTE	0,567	0,536	0,524	0,738	0,310	Aceptado

Cuadro 3: Cinco configuraciones con mayor `ranking_score` en `run_v3_main`. R@K y P@K usan el holdout de cada variante.

“Possible overfitting” indica que se activó al menos uno de los controles de estabilidad entre train, validación cruzada y holdout. Es una advertencia para revisar el modelo; no invalida por sí sola su capacidad de ranking.

Efecto de la selección por paralejo

Cuatro de las cinco primeras configuraciones pertenecen a `photometry`: no aplican un corte previo por el signo o la significancia de la paralejo. Este resultado respalda mantener una rama amplia del experimento. El corte `parallax > 0` reduce la cobertura y una paralejo positiva de baja significancia no constituye por sí sola una medición más fiable que una paralejo negativa compatible con cero.

Las paralejos negativas son resultados válidos del ajuste astrométrico y conservan información sobre fuentes distantes cuando se consideran junto con su incertidumbre [9]. Esta consideración es especialmente relevante para una búsqueda de WR galácticas, cuya muestra incluye objetos distantes y fuentes con astrometría de baja señal. Por esta razón, `photometry` permanece como referencia de cobertura, mientras `poe_2` y `poe_3` permiten medir el comportamiento en subconjuntos con mayor significancia astrométrica. `parallax_soft` queda como control de sensibilidad al corte de signo.

La comparación no demuestra que la paralejo sea irrelevante como feature: los dos sets actuales la incluyen. Demuestra que prefiltrar la población por paralejo no mejora necesariamente el ranking. Una prueba separada con un set formado únicamente por colores sería necesaria para medir el aporte predictivo de la paralejo.

Lectura de los cinco perfiles.

- XGBoost relaxed, ponderación nativa.** Presenta el mejor equilibrio global y recupera 48 de 68 WR en top-100. Sus diagnósticos marcan una advertencia de sobreajuste.
- XGBoost strict, colores y paralejo.** Obtiene un resultado cercano con un set de features más simple y un holdout WR menor.
- XGBoost strict, con errores astrométricos.** Alcanza el mayor Recall@100 entre los tres primeros, acompañado de una AP inferior.

4. **HistGradientBoosting relaxed.** Aporta una familia de estimador distinta, con AP comparable y Recall@100 algo menor.
5. **XGBoost strict_poe_2 con SMOTE.** Es el primer perfil que supera los controles de estabilidad. Recupera 31 de 42 WR en top-100, con menor pureza y un denominador positivo más pequeño.

6. Curvas, interpretación y segunda capa

La Figura 7 compara modelos sobre el mismo holdout `relaxed_photometry`. La curva PR resume la calidad del ranking y la ampliación ROC muestra las diferencias dentro del primer 3 % de FPR.




Figura 7: Curvas PR y ROC sobre un holdout común de `relaxed_photometry`.

El líder de AP es el XGBoost con SMOTE entrenado sobre `relaxed_photometry`, el subconjunto `relaxed` sin preselección astrométrica: AP=0,567 y Recall@100=63,2 %. El ranking compuesto favorece en cambio al XGBoost con ponderación nativa sobre el mismo subconjunto, porque recupera más WR dentro del top-100. La advertencia de estabilidad se evalúa junto con ambas métricas.

La Figura 8 muestra la importancia interna de este último XGBoost, que ocupa el primer lugar del ranking compuesto. W1-W2 y paralaje concentran la mayor ganancia del estimador. Esta lectura describe el modelo ajustado y carece de interpretación causal.




Figura 8: Importancia interna del XGBoost con ponderación nativa entrenado sobre `relaxed_photometry`.

Los modelos anteriores forman la primera capa supervisada y producen el ranking principal. También se evaluó una segunda capa one-class separada para WN y WC, pero sus configuraciones redujeron negativos a costa

de perder WR o conservaron WR con una reducción demasiado pequeña. El experimento queda registrado como diagnóstico y no modifica el ranking operativo.

Aplicación para revisar los resultados

El repositorio incluye una aplicación Streamlit, Model Explorer, como superficie principal de revisión. La aplicación consulta las bases DuckDB y permite comparar configuraciones, inspeccionar PR/ROC, recuperación top-K, estabilidad, importancia de features, composición del holdout, fuentes individuales y el resumen de la segunda capa. La selección de un `run_id` o `result_id` mantiene cada vista vinculada al dataset, las features y el artefacto que produjeron el resultado.

Los notebooks se conservan como auditorías compactas de procedencia, locus, selección de modelos y estado de la prediction pool. La aplicación ofrece una revisión más directa porque permite cambiar de modelo sin editar celdas ni reconstruir manualmente las consultas.

La historia completa de métricas y predicciones de las 144 configuraciones, tres modelos representativos de la primera capa y las bases de referencia se publicaron como un bundle en la [GitHub Release de esta entrega](#). Las métricas de segunda capa permanecen en la base de historia; sus modelos y datasets de ajuste se omitieron del bundle. La instalación aislada, apertura local de la aplicación y verificación de los artefactos se documentan en `InstruccionesDeUso.pdf`.

La siguiente ampliación incorpora información espectral. Gaia DR3 ofrece espectros BP/RP medios [13], productos RVS para subconjuntos de fuentes e información H-alpha en `astrophysical_parameters` [14]. La primera etapa será una auditoría de cobertura común en WR, SIMBAD y prediction pool.

7. Construcción de la prediction pool

La prediction pool reúne fuentes Gaia sin etiqueta sobre las que se aplicarán los modelos seleccionados. Su construcción separa la consulta remota de la elegibilidad para cada modelo. Gaia entrega una capa amplia de adquisición; el pipeline local aplica después las mismas reglas que generaron los datasets de entrenamiento.

Consulta de adquisición

El cielo se divide en 675 regiones de consulta. Para cada región, la consulta ADQL une `gaiadr3.gaia_source` con los best-neighbour oficiales de 2MASS y ALLWISE. Exige G/BP/RP, J/H/Ks y W1/W2, recupera paralaje y sus errores, y conserva columnas diagnósticas de astrometría, fotometría, variabilidad, crossmatch y H-alpha cuando están disponibles. El bloque siguiente resume la consulta; los límites de RA y Dec cambian en cada región.

```
FROM gaiadr3.gaia_source AS gaia
JOIN gaiadr3.tmass_psc_xsc_best_neighbour AS xm USING (source_id)
JOIN gaiadr3.tmass_psc_xsc_join AS xj USING (clean_tmass_psc_xsc_oid)
JOIN gaiadr1.tmass_original_valid AS tmass
  ON xj.original_psc_source_id = tmass.designation
JOIN gaiadr3.allwise_best_neighbour AS wm USING (source_id)
JOIN gaiadr1.allwise_original_valid AS wise
  ON wm.allwise_oid = wise.allwise_oid
LEFT JOIN gaiadr3.astrophysical_parameters AS ap USING (source_id)
WHERE gaia.ra >= :ra_min AND gaia.ra < :ra_max
  AND gaia.dec >= :dec_min AND gaia.dec < :dec_max
  AND gaia.phot_g_mean_mag IS NOT NULL
  AND gaia.phot_bp_mean_mag IS NOT NULL
  AND gaia.phot_rp_mean_mag IS NOT NULL
  AND tmass.j_m IS NOT NULL AND tmass.h_m IS NOT NULL
  AND tmass.ks_m IS NOT NULL
  AND wise.w1mpro IS NOT NULL AND wise.w2mpro IS NOT NULL
  AND <cada color dentro de los limites de la Tabla 4>
```

La consulta limita siete colores intra-misión a una envolvente rectangular derivada de las 347 WR con fotometría completa en `relaxed_photometry`. Cada intervalo incluye un margen de al menos 0,15 mag, o 5 % del rango observado cuando este valor es mayor.

Color	Límite inferior	Límite superior
G-BP	-4,9996	0,2616
G-RP	-0,1824	2,3853
BP-RP	-0,3716	6,8623
J-H	-0,1460	2,8480
J-Ks	-0,1346	4,4106
H-Ks	-0,0820	2,1750
W1-W2	-2,1487	2,1567

Cuadro 4: Límites de color aplicados en la consulta de adquisición.

La consulta remota no corta por signo de la paralaje, POE, calidad A/B ni por la regla final del locus. Esos valores se descargan para aplicar localmente la combinación correspondiente a cada modelo. La pool requiere las rutas de crossmatch de Gaia hacia 2MASS y AllWISE; el fallback de VizieR usado para completar la referencia WR no forma parte de esta consulta.

Los filtros se repiten antes de cada predicción

Para una variante v , la compatibilidad de una fuente se calcula como:

$$E_v = L_v \wedge Q_v \wedge A_v,$$

donde L_v aplica el locus ajustado para esa variante, Q_v aplica la calidad `strict` o `relaxed`, y A_v aplica el requisito astrométrico: ninguno para `photometry`, paralaje positiva para `parallax_soft`, o paralaje positiva y el POE correspondiente para `poe`. La fuente se procesa con un modelo m únicamente cuando:

$$\text{score}(x, m) \iff E_{v_m}(x) \wedge F_m(x),$$

donde v_m es la variante usada para entrenar el modelo y F_m indica que están presentes todas sus features. Por tanto, una fuente que cumple `relaxed_photometry` y tiene una paralaje finita negativa puede recibir el score de ese modelo; queda fuera de los modelos `relaxed_parallax_soft`, `relaxed_poe_2` y `relaxed_poe_3`. Cada predicción repite así todos los filtros aplicados al dataset del modelo correspondiente.

Fuentes adquiridas, elegibles y bitmask

Las **fuentes adquiridas** son las filas devueltas por la consulta ADQL y guardadas en la capa física. Las **fuentes elegibles** cumplen de forma completa al menos una variante y quedan fuera de las listas WR y SIMBAD usadas para construir las etiquetas. La diferencia entre ambos conteos aparece al aplicar localmente el locus, la calidad fotométrica, la astrometría y las exclusiones conocidas.

La pool registra doce variantes: seis reglas astrométricas para `strict` y las mismas seis para `relaxed`. La grilla principal utiliza ocho; `poe_1` y `poe_5` quedan anotadas para auditorías o experimentos posteriores.

Una máscara de bits, *bitmask*, guarda en un entero qué variantes cumple cada fuente. Un bit se activa únicamente cuando locus, calidad y astrometría son verdaderos para esa variante. Antes de ejecutar un modelo, el scorer consulta el bit asociado a su dataset:

$$(\text{compatible_variant_mask} \& 2^{b_{v_m}}) \neq 0.$$

La bitmask permite conservar una fila por fuente, dirigirla solamente a los modelos compatibles y auditar por separado si una exclusión provino del locus, la calidad fotométrica o la astrometría.

Estado actual

El build se ejecuta bajo el identificador técnico `pool_exact_union_acquisition_v1`. En el snapshot del 26 de julio de 2026 se habían completado 673 de 675 regiones, con dos regiones fallidas: 184,8 millones de fuentes adquiridas y 64,9 millones elegibles para scoring. Antes de iniciar el ranking se reintentarán esas regiones y se auditarán la cobertura y los manifiestos del build.

El paso pendiente es completar y auditar la prediction pool. Después se seleccionarán explícitamente los modelos y se generará el ranking de candidatas.

Referencias

- [1] Rosslowe, C. K. y Crowther, P. A. (2015). "Spatial distribution of Galactic Wolf-Rayet stars and implications for the global population". *MNRAS*, 447, 2322–2347. doi:10.1093/mnras/stu2525.
- [2] Crowther, P. A. *Galactic Wolf Rayet Catalogue*. Snapshot local v1.33 (Gaia DR3), 705 WR, agosto de 2025. <https://pacrowther.staff.shef.ac.uk/WRcat/>.
- [3] Gaia Collaboration, Vallenari, A. et al. (2023). "Gaia Data Release 3: Summary of the content and survey properties". *A&A*, 674, A1. doi:10.1051/0004-6361/202243940.
- [4] Skrutskie, M. F. et al. (2006). "The Two Micron All Sky Survey (2MASS)". *AJ*, 131, 1163–1183. doi:10.1086/498708.
- [5] Wright, E. L. et al. (2010). "The Wide-field Infrared Survey Explorer (WISE): Mission Description and Initial On-orbit Performance". *AJ*, 140, 1868–1881. doi:10.1088/0004-6256/140/6/1868.
- [6] Wenger, M. et al. (2000). "The SIMBAD astronomical database". *A&AS*, 143, 9–22. doi:10.1051/aas:2000332.
- [7] Ochsenbein, F., Bauer, P. y Marcout, J. (2000). "The VizieR database of astronomical catalogues". *A&AS*, 143, 23–32. doi:10.1051/aas:2000169.
- [8] Huber, P. J. (1964). "Robust Estimation of a Location Parameter". *The Annals of Mathematical Statistics*, 35(1), 73–101. doi:10.1214/aoms/1177703732.
- [9] Luri, X. et al. (2018). "Gaia Data Release 2: Using Gaia parallaxes". *A&A*, 616, A9. doi:10.1051/0004-6361/201832964.
- [10] Chen, T. y Guestrin, C. (2016). "XGBoost: A Scalable Tree Boosting System". *Proceedings of KDD '16*, 785–794. doi:10.1145/2939672.2939785.
- [11] Chawla, N. V., Bowyer, K. W., Hall, L. O. y Kegelmeyer, W. P. (2002). "SMOTE: Synthetic Minority Over-sampling Technique". *JAIR*, 16, 321–357. doi:10.1613/jair.953.
- [12] Saito, T. y Rehmsmeier, M. (2015). "The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets". *PLOS ONE*, 10(3), e0118432. doi:10.1371/journal.pone.0118432.
- [13] De Angeli, F. et al. (2023). "Gaia Data Release 3: Processing and validation of BP/RP low-resolution spectral data". *A&A*, 674, A2. doi:10.1051/0004-6361/202243680.
- [14] Fouesneau, M. et al. (2023). "Gaia Data Release 3: Apsis. I. Methods and content overview". *A&A*, 674, A28. doi:10.1051/0004-6361/202243688.